



Meetup Vortrag 19.02.19 – Martin & Florian




Wie man einer KI das Spielen beibringt




Hintergrund: Hackathon

1. Reinforcement Learning verstehen
2. Entscheidung für ein Spiel
3. Spiel entwickeln
4. Algorithmus entwerfen
5. Modell trainieren



Das Spiel

Wir sind ein Lagerarbeiter mit der Aufgabe bestimmte Pakete so schnell wie möglich einzusammeln und zum Lagerausgang zu bringen.






Reinforcement Learning

Reinforcement Learning

- Environment liefert State (Zustand) und Reward (Belohnung) an den Agent
- Agent entscheidet sich für eine Action und liefert diese an das Environment
- Interaktion passiert in diskreten Zeitschritten
- Reward r_{t+1} wird vom Agent in Verbindung gesetzt mit dem Übergang (s_t, a_t, s_{t+1}) wobei s_t den State und a_t die Action zum Zeitpunkt t darstellt
- Herausforderung: Langfristige vs kurzfristige Auswirkungen



Q-Learning

- $Q^{new}(s_t, a_t) = (1 - \alpha) \times Q(s_t, a_t) + \alpha \times \underbrace{(r_t + \gamma \times \max_a Q(s_{t+1}, a))}_{\text{„Gelernter“ Wert}}$
- γ – Discount, je größer desto stärker werden zukünftige Belohnungen gewichtet
- α – Lernrate, „explore“ ($\alpha = 1$) vs „exploit“ ($\alpha = 0$)
- r_t – Belohnung
- s_t – Zustand
- a_t – Aktion

Anwendungen – DeepMind

- In 2010 gegründetes Unternehmen
- In 2014 von Google übernommen
- Entwicklung von AI im Bereich Medizin
- Forschung im Bereich Reinforcement Learning bei Spielen (Arcade-Games, Strategie Spiele)

Anwendung – DeepMinds AlphaZero


- Erste Entwicklung für atari Arcade Spiele
- AlphaGo: Programm für das Strategiespiel Go – Sieg gegen den stärksten Go-Spieler in 2017
- Weiterentwicklung zu AlphaZero: Erfolge in Go, Shogi und Schach
 - Lernt durch Spielen gegen sich selbst
 - Generalisierter Algorithmus, der vorherige Versionen (AlphaGo) und andere KIs (Stockfish, Elmo,...) besiegt (unter teilweise kritischen Bedingungen)
 - AlphaZero rechnet ca. 80.000 Positionen pro Sekunde (Schach), Stockfish rechnet 70 Millionen
- Während herkömmliche Engines auf Regeln und Heuristiken beruhen, basiert DeepMind auf einem neuronalen Netz

Ergebnisse gegen State-of-the-Art-Engines


Chess




AlphaZero vs. Stockfish



Shogi




AlphaZero vs. Elmo



Go



AlphaZero vs. AGO



Anwendung – AlphaStar

- KI zum Spielen des Echtzeitstrategiespiels Starcraft II
- Basis: Aufgezeichnete Spiele von professionellen SC II Spielern und Spielen gegen sich selbst
- Über 200 Jahre Spielerfahrung und Siege gegen professionelle Spieler




Weitere Implementierungen

- Super Mario. Bros
- Autofahren GTA V
- Flappy Bird
- ...



Entwicklung des Spiels


- Mit pygame (python Paket)
- Rechtecke, die alle 10 ms neu gezeichnet werden
- Input: Up, Down, Right, Left, Space
- 400 Züge
- Ziel: Einsammeln mind. Eines Items und finden des Ausgangs
- Sekundäres Ziel: Nicht gegen Regal (Game Over) oder Wand fahren (Punktabzug)



Punktesystem

- +6 pts - Einsammeln eines Items
- -4 pts - Fahren gegen die Wand
- -1 pts – Drücken der Leertaste (ohne Einsammeln eines Items)
- $+(3 + \text{Anzahl der verbliebenen Züge})$ pts – Finden des Ausgangs
- -10 pts – Fahren gegen Regal

Wie spielt die KI?




```
[[0 0 0]
 [0 0 0]
 [0 0 0]
 ...
 [0 0 0]
 [0 0 0]
 [0 0 0]]]
```




```
[0.253, 0.155, 0.346, 0.103, 0.269]
```



K_RIGHT






```
[[0 0 0]
 [0 0 0]
 [0 0 0]
 ...
 [0 0 0]
 [0 0 0]
 [0 0 0]]]
```



[0.489, 0.031, 0.812, 0.261, 0.948]



K SPACE



Experience

+6 pts





Algorithmus: Designentscheidungen

```
1
2 possibleInput = [K_UP, K_DOWN, K_RIGHT, K_LEFT, K_SPACE]
3 epsilon = 0.1
4 num_actions = 5 # left, right, up, down, pickup
5
6 batch_size = 15
7 discount = 0.7
8 grid_size = 580*500
9
10 hidden_size = 100
11
12 # function for model definition
13 def baseline_model(grid_size, num_actions, hidden_size):
14     #setting up the model with keras
15     model = Sequential()
16     model.add(Dense(hidden_size, input_shape=(grid_size,), activation='tanh'))
17     model.add(Dense(hidden_size, activation='tanh'))
18     model.add(Dense(5, activation = "linear"))
19     model.compile(sgd(lr=.01), "mse")
20     return model
```

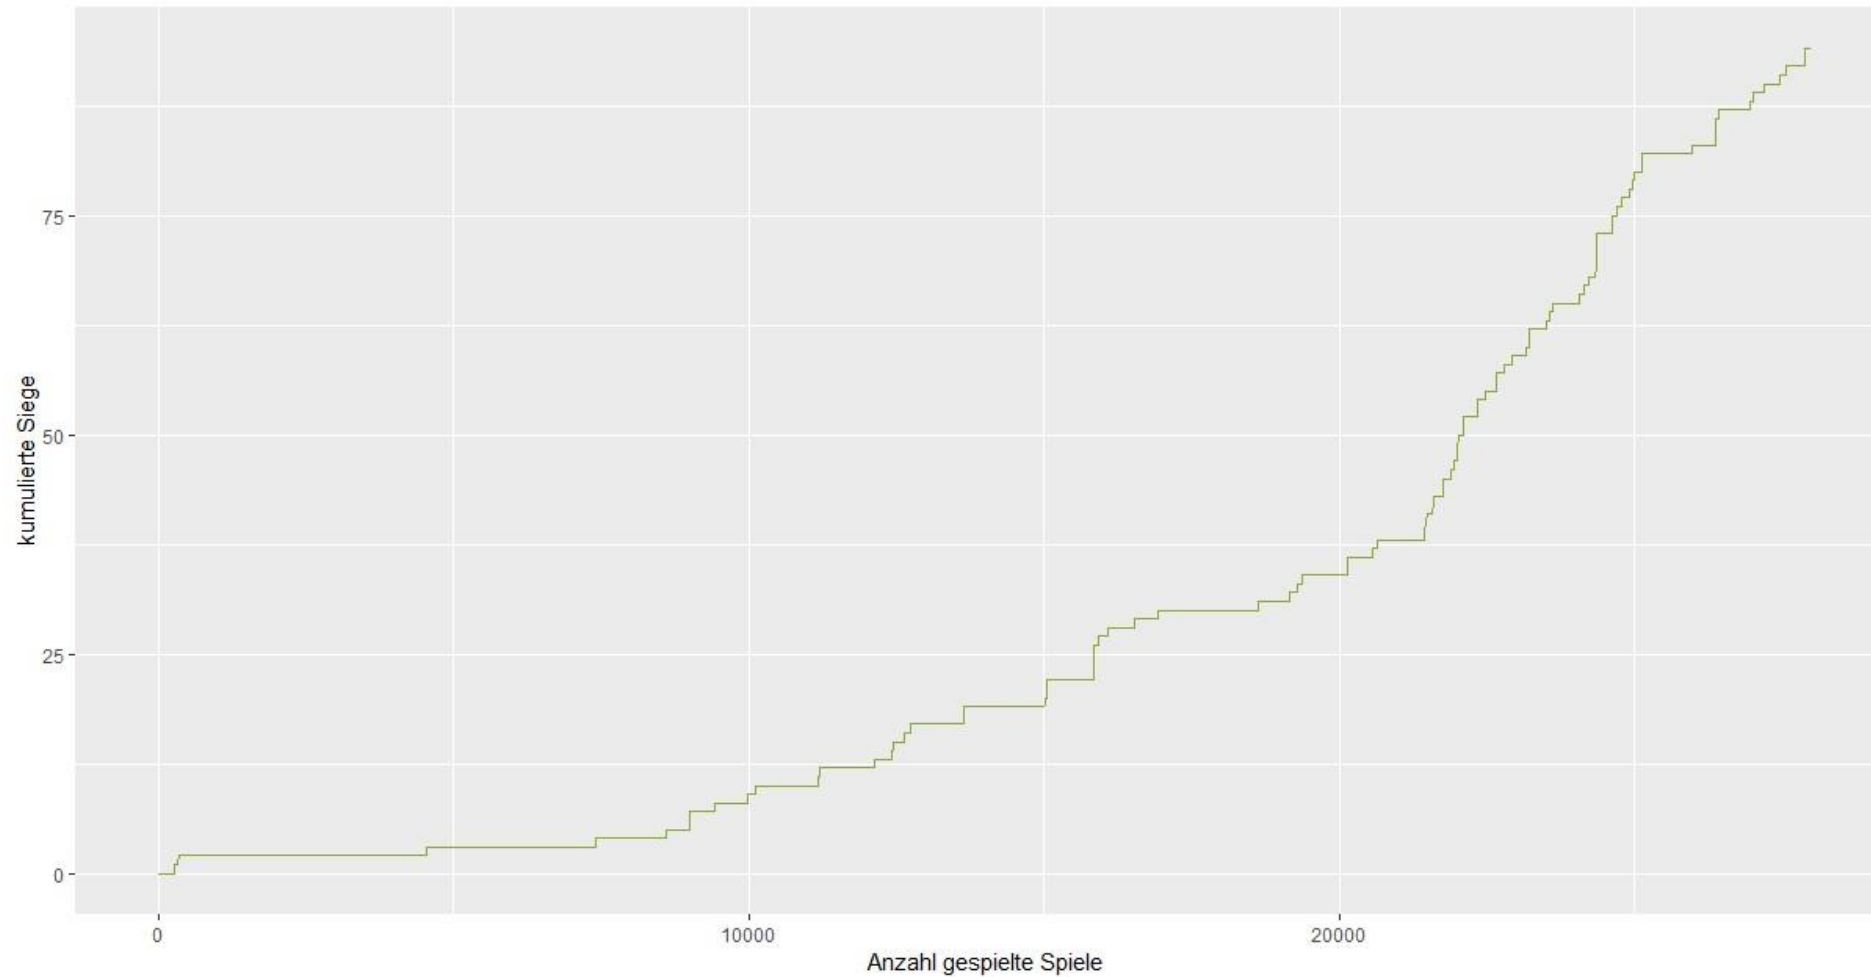

Ergebnisse







Ergebnisse – kumulierte Siege



Verbesserungsmöglichkeiten

- Design des neuronalen Netz (Wahl der Aktivierungsfunktionen, Anzahl der Layer,...)
- Form des Inputs (1D/2D-Array, ...)
- Punktevergabe
- Wahl der Parameter (Zufallszüge, batch-Size, ...)
- Mehr Lernen: Bis jetzt „nur“ ca. 25000 Durchläufe



Jobs mit Perspektive in der Branche der Zukunft

Wir suchen Unterstützung in den Bereichen:

Data Science

Softwareentwicklung

IT-System Engineering

Sales

Mehr Informationen auf unserer Karriereseite.



Die Data Science Spezialisten.

eoda GmbH

Universitätsplatz 12

34127 Kassel

www.eoda.de

info@eoda.de

+49 561 202724-40



@eodaGmbH



blog.eoda.de



@eodaGmbH



[eodaGmbH](https://www.youtube.com/eodaGmbH)